

JULHO DE 2025



Uma Análise Comparativa de Modelos Colaborativos, Baseados em Conteúdo e Híbridos em Sistemas de Recomendação de Filmes

**DANIEL ESTEVAM
FERNANDO COUTO
LUCAS LIMA
TITO CHEN
VINICIUS LIMA**



Introdução

O DESÁFIO DA RELEVÂNCIA NA ERA DA INFORMAÇÃO

- **Crescimento exponencial de informações online**
- **Dificuldade dos usuários de encontrar conteúdo relevante**
- **Papel dos sistemas de recomendação**



Aplicações Práticas

ONDE OS SISTEMAS DE SISTEMAS DE RECOMENDAÇÃO SÃO UTILIZADOS

- **Streaming: Netflix, Disney+, Amazon Prime**
- **E-commerce: Amazon, Mercado Livre**
- **Redes Sociais: Instagram, TikiTok**



Metodologia


Seleção e preparação dos dados

Definição dos modelos de recomendação

Métricas

Implementação dos algoritmos

Avaliação dos resultados.



Metodologia

Seleção e preparação dos dados



1.

BASE DE DADOS

Base de dados pública
MovieLens 100k

2.

PRÉ PROCESSAMENTO

Matriz de utilidade no
formato usuário x filme

3.

CONJUNTOS

Treino com 80% da base
Teste com 20% da base

4.

GENEROS

Vetores binários indicando
a presença ou ausência de
cada gênero.



Metodologia

MODELOS DE RECOMENDAÇÃO

1.

FILTRAGEM COLABORATIVA BASEADA EM USUÁRIO

Algoritmo de K-Nearest
Neighbors (KNN)
Similaridade entre
usuários

2.

FATORAÇÃO DE MATRIZES (SVD)

Singular Value
Decomposition (SVD)

3.

RECOMENDAÇÃO BASEADA EM CONTEÚDO

Gêneros dos filmes para
calcular a similaridade
entre itens

4.

MODELO HÍBRIDO

SVD + Recomendação
Baseada em conteúdo

Metodologia

Métricas



1.

ROOT MEAN SQUARED ERROR (RMSE)
MEAN ABSOLUTE ERROR (MAE)

Mensuram a diferença entre as avaliações previstas e as avaliações reais dos usuários (KNN & SVD)

2.

PRECISION@K
RECALL@K

Avaliam qualidade das top-K recomendações (conteúdo)

3.

SCORE HÍBRIDO

Média ponderada dos scores de SVD e modelo baseado em conteúdo

Metodologia

Implementação dos algoritmos



1.

EXECUÇÃO NO COLAB

Treinamento e testes realizados no Colab

2.

PYTHON

Código desenvolvidos em Python

3.

IMPLEMENTAÇÃO DOS MODELOS

Bibliotecas pandas, numpy, scikit-learn e surprise

4.

RESULTADOS

Bibliotecas matplotlib e seaborn



Resultados

AVALIAÇÃO DOS RESULTADOS.

1.

FILTRAGEM COLABORATIVA (KNN)

RMSE = 1,0194
MAE = 0,8038

Reflete uma capacidade moderada de prever as avaliações dos usuários

2.

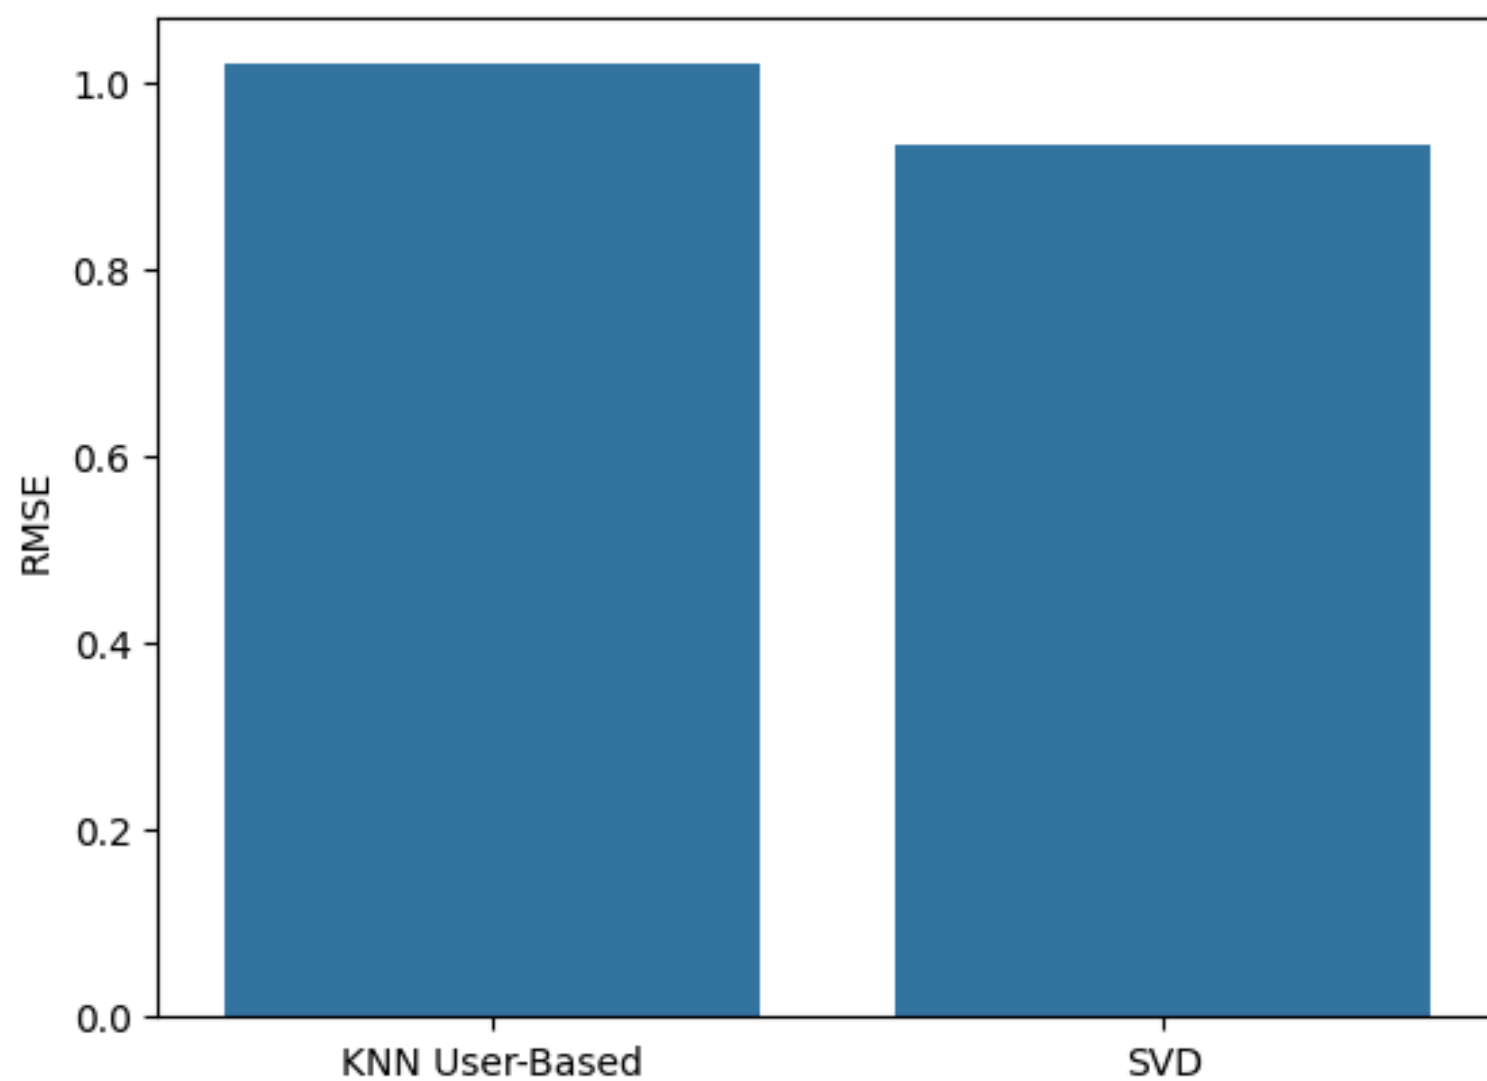
FATORAÇÃO DE MATRIZES (SVD)

RMSE = 0,9341
MAE = 0,7364

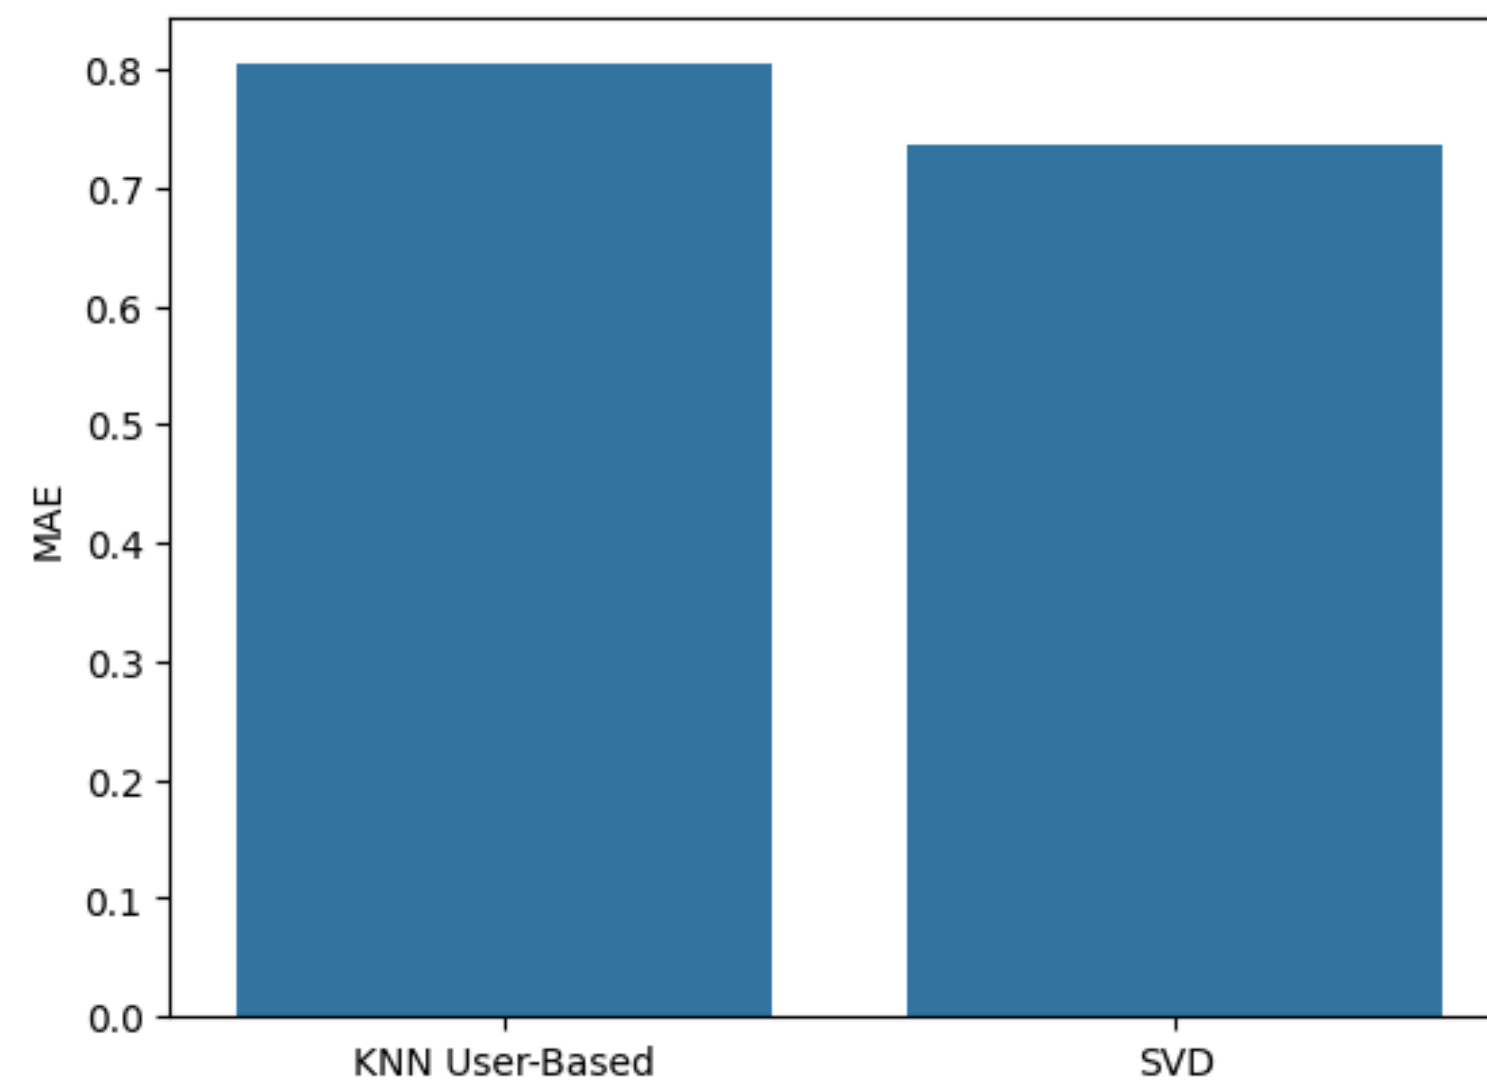
Resultados superiores ao KNN, reforçando a eficácia da fatoração de matrizes em capturar padrões latentes

Resultados

RMSE dos Modelos



MAE dos Modelos





Resultados

AVALIAÇÃO DOS RESULTADOS.

3.

RECOMENDAÇÃO BASEADA EM CONTEÚDO

Precision@10 e
Recall@10 igual a zero

Limitado pela escassez
de informações
descritivas na base de
dados utilizada

4.

MODELO HÍBRIDO

Score = 1,8576

Obtido com exemplo
específico de usuário e
filme. Não houve
experimentação em larga
escala

Conclusões



1.

FATORAÇÃO DE MATRIZES (SVD)

**Melhor desempenho.
Modelos baseados em
fatoração são mais
eficientes em cenários com
alta esparsidade de dados**

2.

CONTEÚDO

**Insatisfatório no dataset
escolhido**

3.

HÍBRIDO

Demonstrou-se promissor

Bibliografia

Andrew Schein et al. “Methods and Metrics for Cold-Start Recommendations”. In: SIGIR Forum (ACM Special Interest Group on Information Retrieval). Aug. 2002, pp. 253–260. DOI: 10.1145/564376.564421.

G. Adomavicius and A. Tuzhilin. “Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions”. In: IEEE Transactions on Knowledge and Data Engineering 17.6 (2005), pp. 734–749. DOI: 10.1109/TKDE.2005.99.

Asela Gunawardana and Guy Shani. “A Survey of Accuracy Evaluation Metrics of Recommendation Tasks”. In: Journal of Machine Learning Research 10.100 (2009), pp. 2935–2962. URL: <http://jmlr.org/papers/v10/gunawardana09a.html>.

Yehuda Koren, Robert Bell, and Chris Volinsky. “Matrix Factorization Techniques for Recommender Systems”. In: Computer 42.8 (2009), pp. 30–37. DOI: 10.1109/MC.2009.263.

Francesco Ricci, Lior Rokach, and Bracha Shapira. “Recommender Systems Handbook”. In: vol. 1-35. Oct. 2010, pp. 1–35. ISBN: 978-0-387-85819-7. DOI: 10.1007/978-0-387-85820-3_1.

Gilbert Badaro et al. “A hybrid approach with collaborative filtering for recommender systems”. In: 2013 9th International Wireless Communications and Mobile Computing Conference (IWCMC). 2013, pp. 349–354. DOI: 10.1109/IWCMC.2013.6583584.

Erion Çano and Maurizio Morisio. “Hybrid recommender systems: A systematic literature review”. In: Intelligent Data Analysis 21.6 (Nov. 2017), pp. 1487–1524. ISSN: 1571-4128. DOI: 10.3233/ida-163209. URL: <http://dx.doi.org/10.3233/IDA-163209>.

Xiangnan He et al. Neural Collaborative Filtering. 2017. arXiv: 1708.05031 [cs.IR]. URL: <https://arxiv.org/abs/1708.05031>.

Shuai Zhang et al. “Deep Learning Based Recommender System: A Survey and New Perspectives”. In: ACM Computing Surveys (July 2017). DOI: 10.1145/3285029.

Bibliografia

Rui Chen et al. "A Survey of Collaborative Filtering-Based Recommender Systems: From Traditional Methods to Hybrid Methods Based on Social Networks". In: IEEE Access 6 (2018), pp. 64301–64320. DOI: 10.1109/ACCESS.2018.2877208.

Muhammet Cakir, Sule Gunduz Oguducu, and Resul Tugay. A Deep Hybrid Model for Recommendation Systems. 2020. arXiv: 2009.09748 [cs.LG]. URL: <https://arxiv.org/abs/2009.09748>.

Ziyuan Xia et al. Contemporary Recommendation Systems on Big Data and Their Applications: A Survey. 2024. DOI: <https://doi.org/10.1109/ACCESS.2024.3517492>. arXiv: 2206.02631 [cs.IR]. URL: <https://arxiv.org/abs/2206.02631>.

Ziyuan Xia et al. Contemporary Recommendation Systems on Big Data and Their Applications: A Survey. 2024. DOI: <https://doi.org/10.1109/ACCESS.2024.3517492>. arXiv: 2206.02631 [cs.IR]. URL: <https://arxiv.org/abs/2206.02631>.

**Muito
obrigado!**